Tutorial de Deep Learning

Luiz Gustavo Hafemann
LIVIA
École de Technologie Supérieure – Montréal

Organização do tutorial

- **Dia 1:**
  - Introdução à aprendizagem de máquina
  - Computação simbólica com Theano
- **Dia 2**
  - Redes neurais convolucionais

  Dia 3
  - Transfer Learning

Introdução à aprendizagem de máquina

Introdução à aprendizagem de máquina

Aprender funções à partir de dados

Introdução à aprendizagem de máquina

Aprender funções à partir de dados

- **Aprendizagem supervisionada:**
  - Classificação: classificar SPAM, reconhecimento de objetos
    - Saída categórica: $y = f(\mathbf{x})$ $y \in \{y_1, ..., y_n\}$

Introdução à aprendizagem de máquina

Aprender funções à partir de dados

- **Aprendizagem supervisionada:**
  - Classificação: classificar SPAM, reconhecimento de objetos
    - Saída categórica: $y = f(\mathbf{x}) \qquad y \in \{y_1, ..., y_n\}$
  - Regressão: Preço de imóveis, análise de series de dados
    - Saída contínua: $y = f(\mathbf{x}) \qquad y \in \mathbb{R}$

Introdução à aprendizagem de máquina

Aprender funções à partir de dados

- **Aprendizagem supervisionada:**
  - Classificação: classificar SPAM, reconhecimento de objetos
    - Saída categórica: $y = f(\mathbf{x}) \qquad y \in \{y_1, ..., y_n\}$
  - Regressão: Preço de imóveis, análise de series de dados
    - Saída contínua: $y = f(\mathbf{x}) \qquad y \in \mathbb{R}$

- **Aprendizagem não-supervisionada**
  - Clustering (agrupamento), detecção de anomalias

Aprendizagem supervisionada - classificação

Aprendizagem supervisionada - classificação

Formulação do problema

Aprendizagem supervisionada - classificação

Formulação do problema

Dado um conjunto de exemplos $(\mathbf{x}^{(i)}, y^{(i)})$, onde

Aprendizagem supervisionada - classificação

Formulação do problema

Dado um conjunto de exemplos $(\mathbf{x}^{(i)}, y^{(i)})$, onde

$\mathbf{x} = [x_1, x_2, ..x_n]$ **são medidas de entrada**

Aprendizagem supervisionada - classificação

Formulação do problema

Dado um conjunto de exemplos $(\mathbf{x}^{(i)}, y^{(i)})$, onde

$\mathbf{x} = [x_1, x_2, ..x_n]$ **são medidas de entrada**

y **é a classe correta**

Aprendizagem supervisionada - classificação

Formulação do problema

Dado um conjunto de exemplos $(\mathbf{x}^{(i)}, y^{(i)})$, onde

$\mathbf{x} = [x_1, x_2, ..x_n]$ **são medidas de entrada**

y **é a classe correta**

O objetivo é aprender uma função que associe x à y:

$$y_{\text{pred}} = f(\mathbf{x})$$

Que generalize para novas entradas x

Aprendizagem supervisionada - classificação

Exemplo:

Problema de 2 classes: classificar um peixe entre truta e salmão:

$$y \in \{\text{truta}, \text{salmão}\}$$

Duas medidas de entrada: comprimento e luminosidade:

$$\mathbf{x} = \{x_1, x_2\}$$

Aprendizagem supervisionada - classificação

50 exemplos são adquiridos para cada classe:

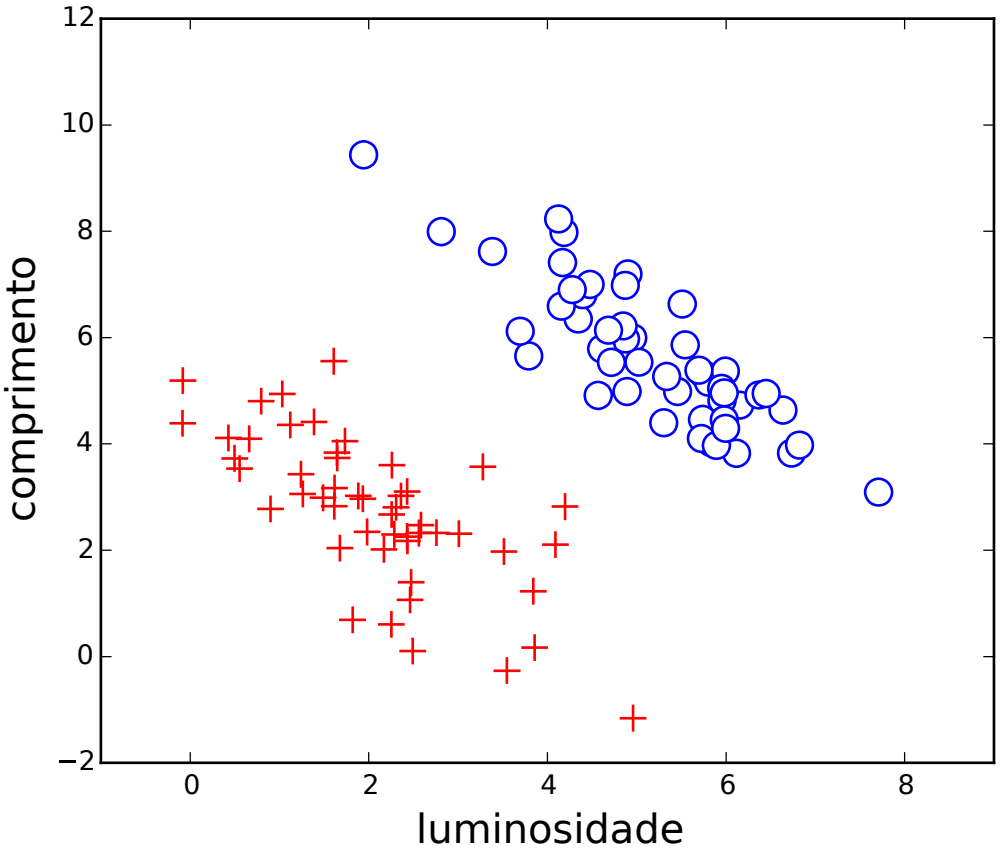

Aprendizagem supervisionada - classificação

Treinamento de um modelo

(nesse exemplo, um modelo paramétrico:)

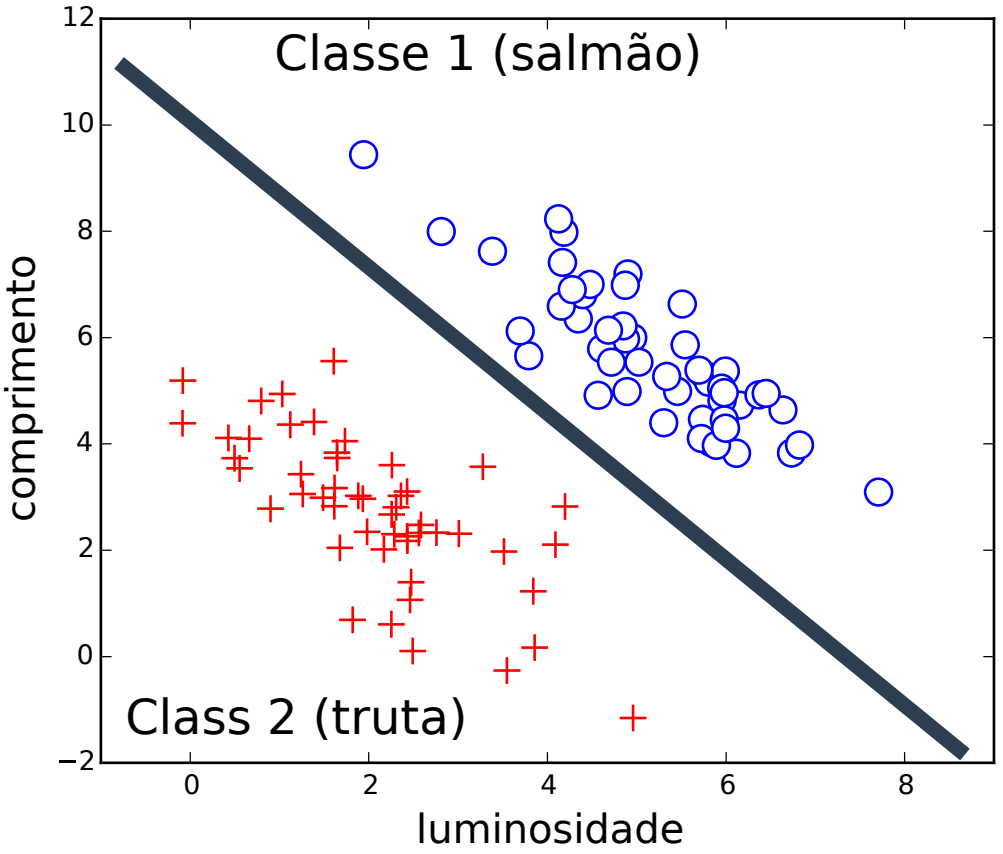

Aprendizagem supervisionada - classificação

Generalização para novos exemplos

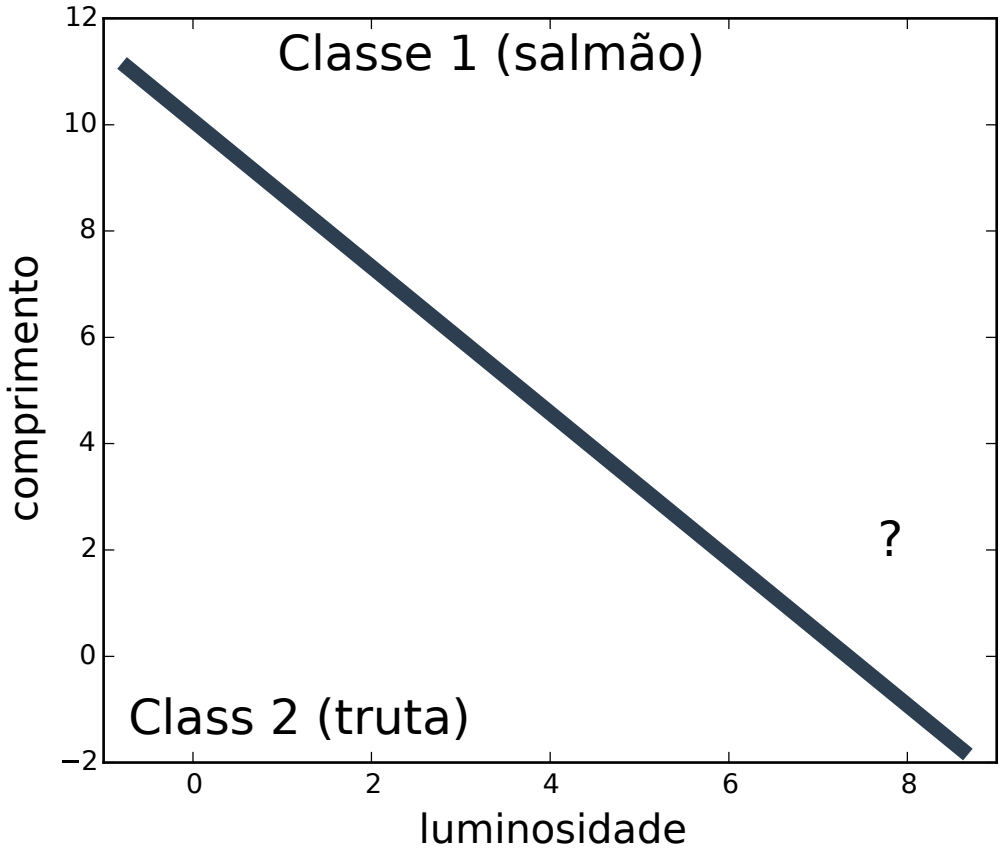

Aprendizagem supervisionada

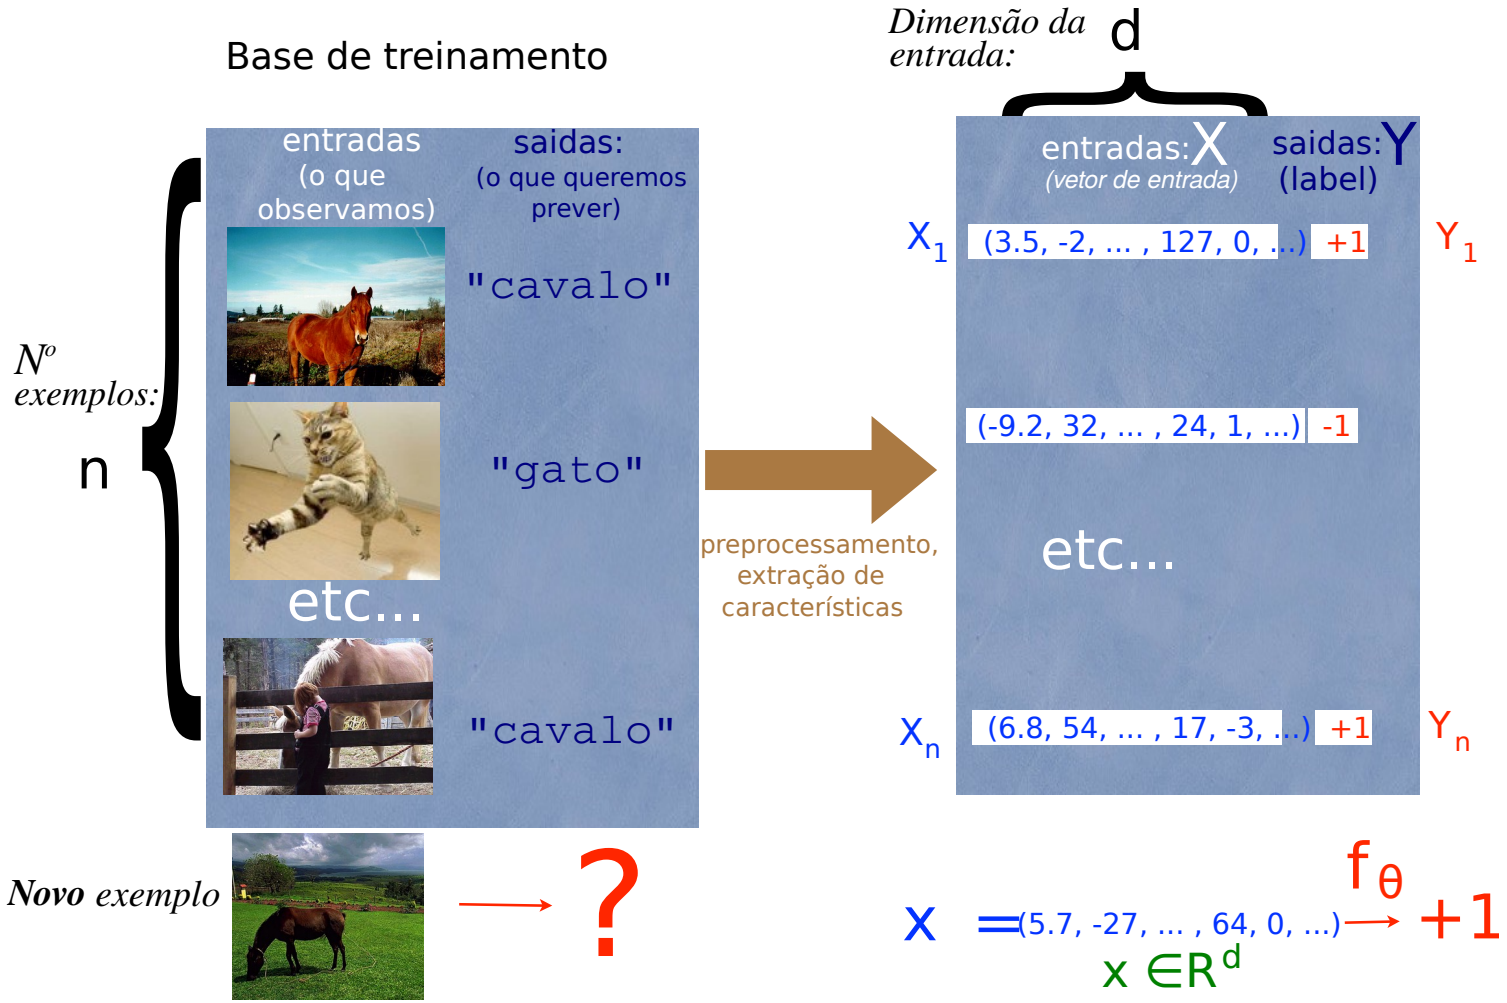

Slide de Pascal Vincent

Aprendizagem supervisionada

Avião

Carro

Avião

Carro

Slide de
Yann Lecun

3 elementos básicos

3 elementos básicos

Escolher a família de funcões

Geralemente paramétricas, (e.g. “Regressão logística”)

3 elementos básicos

Escolher a família de funcões

Geralemente paramétricas, (e.g. “Regressão logística”)

Uma medida para avaliar f

Função de custo → quanto menor, melhor o modelo

3 elementos básicos

Escolher a família de funcões

Geralemente paramétricas, (e.g. “Regressão logística”)

Uma medida para avaliar f

Função de custo → quanto menor, melhor o modelo

Uma forma de buscar o melhor f

Processo de otimização → como encontrar os parâmetros que minimizem a função de custo

Regressão logística

Regressão logística

Família de funções:

Combinação linear da entrada: $w_1 x_1 + w_2 x_2 ... w_m x_m$

Usa-se uma função não linear ao fim para obter resultados entre [0,1]

$$\hat{y} = P(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^\intercal \mathbf{x})$$

Regressão logística

Família de funções:

Combinação linear da entrada: $w_1 x_1 + w_2 x_2 ... w_m x_m$

Usa-se uma função não linear ao fim para obter resultados entre [0,1]

$$\hat{y} = P(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^\intercal \mathbf{x})$$

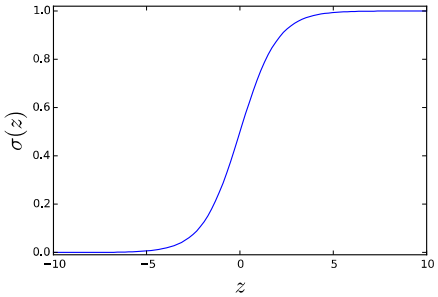

Regressão logística

Família de funções:

Combinação linear da entrada: $w_1 x_1 + w_2 x_2 ... w_m x_m$

Usa-se uma função não linear ao fim para obter resultados entre [0,1]

$$\hat{y} = P(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^\intercal \mathbf{x})$$

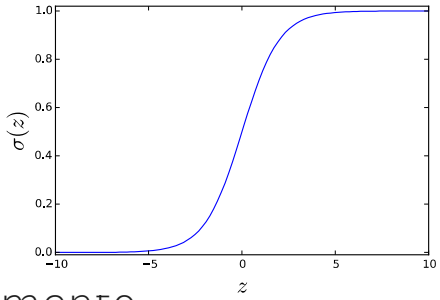

Objetivo:

Maximizar $P(y = y^{(i)}|\mathbf{x}^{(i)})$ para os exemplos na base de treinamento

Equivalente à minimizar:

$$-\sum_i \log P(y = y^{(i)}|\mathbf{x}^{(i)})$$

Regressão logística

Família de funções:

Combinação linear da entrada: $w_1 x_1 + w_2 x_2 ... w_m x_m$

Usa-se uma função não linear ao fim para obter resultados entre [0,1]

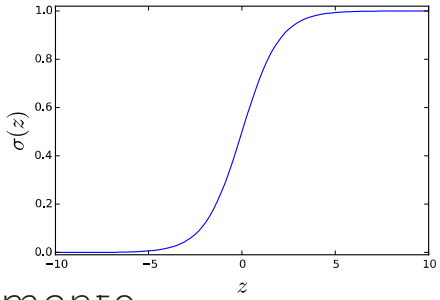

$$\hat{y} = P(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^\intercal \mathbf{x})$$

Objetivo:

Maximizar $P(y = y^{(i)}|\mathbf{x}^{(i)})$ para os exemplos na base de treinamento

Equivalente à minimizar:

$$-\sum_i \log P(y = y^{(i)}|\mathbf{x}^{(i)})$$

Optimização:

Descida de gradiente: Começando com w aleatório, dando pequenos passos para diminuir a função de custo

Regressão logística

Regressão logística

Função de custo, dado saída do modelo: $\hat{y} = P(y = 1|\mathbf{x})$

$$L = -\frac{1}{N}\sum_{i=1}^{N} \log P(y = y^{(i)}|\mathbf{x}^{(i)})$$

$$L = -\frac{1}{N}\sum_{i=1}^{N} y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$$

Regressão logística

Função de custo, dado saída do modelo: $\hat{y} = P(y = 1|\mathbf{x})$

$$L = -\frac{1}{N}\sum_{i=1}^{N} \log P(y = y^{(i)}|\mathbf{x}^{(i)})$$

$$L = -\frac{1}{N}\sum_{i=1}^{N} y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$$

Optimização:

Início: $\mathbf{w}^{(0)} = \text{random}$

Por T iterações:

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \alpha \nabla_{\mathbf{w}} L$$

Regressão logística

Função de custo, dado saída do modelo: $\hat{y} = P(y = 1|\mathbf{x})$

$$L = -\frac{1}{N}\sum_{i=1}^{N} \log P(y = y^{(i)}|\mathbf{x}^{(i)})$$

$$L = -\frac{1}{N}\sum_{i=1}^{N} y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)})$$

Optimização:

Início: $\mathbf{w}^{(0)} = \text{random}$

Por T iterações:

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \alpha \nabla_{\mathbf{w}} L$$

Calculando $\nabla_{\mathbf{w}} L$:

Usamos a regra de cadeia –ou software que a calcule automaticamente (e.g. Theano)

Visualizando a função de custo

Custo como função dos parametros w_1, w_2:

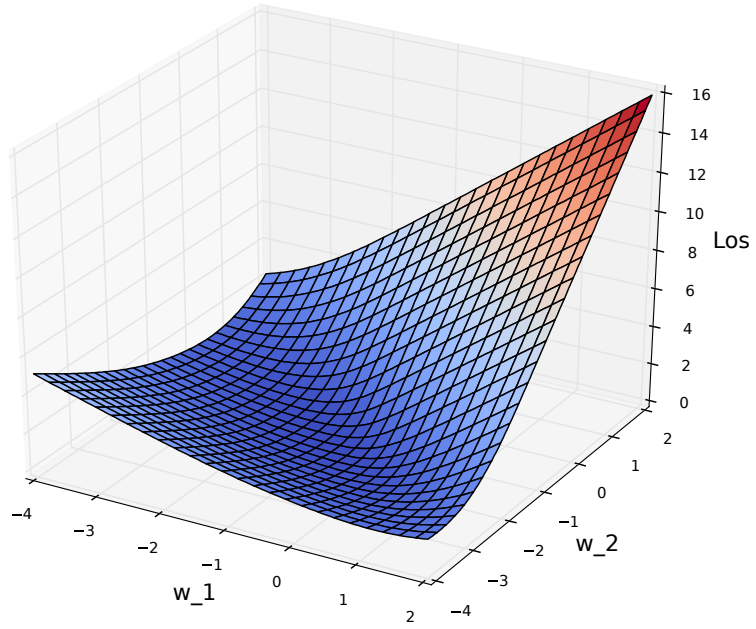

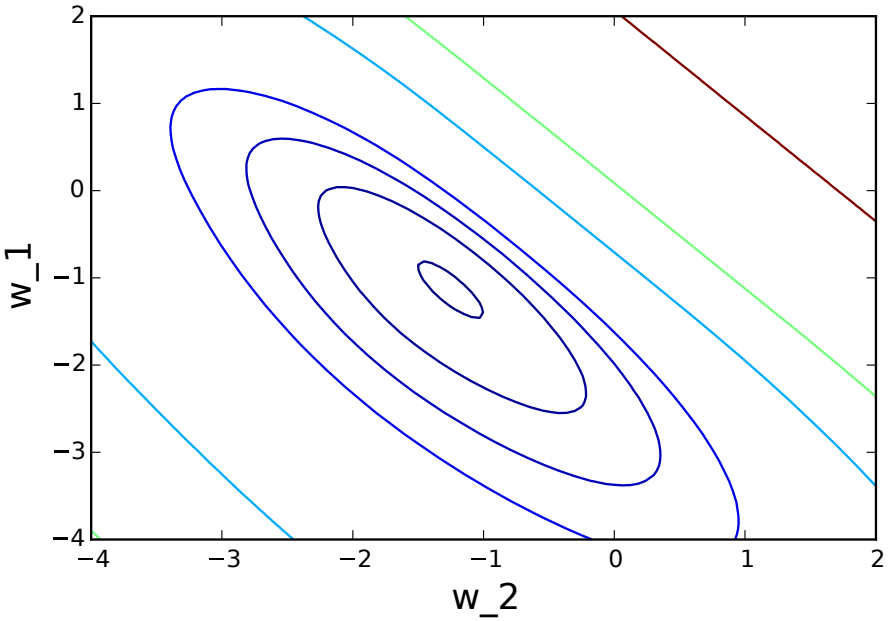

Descida de gradiente

$\mathbf{w}^{(0)}$
(aleatório)

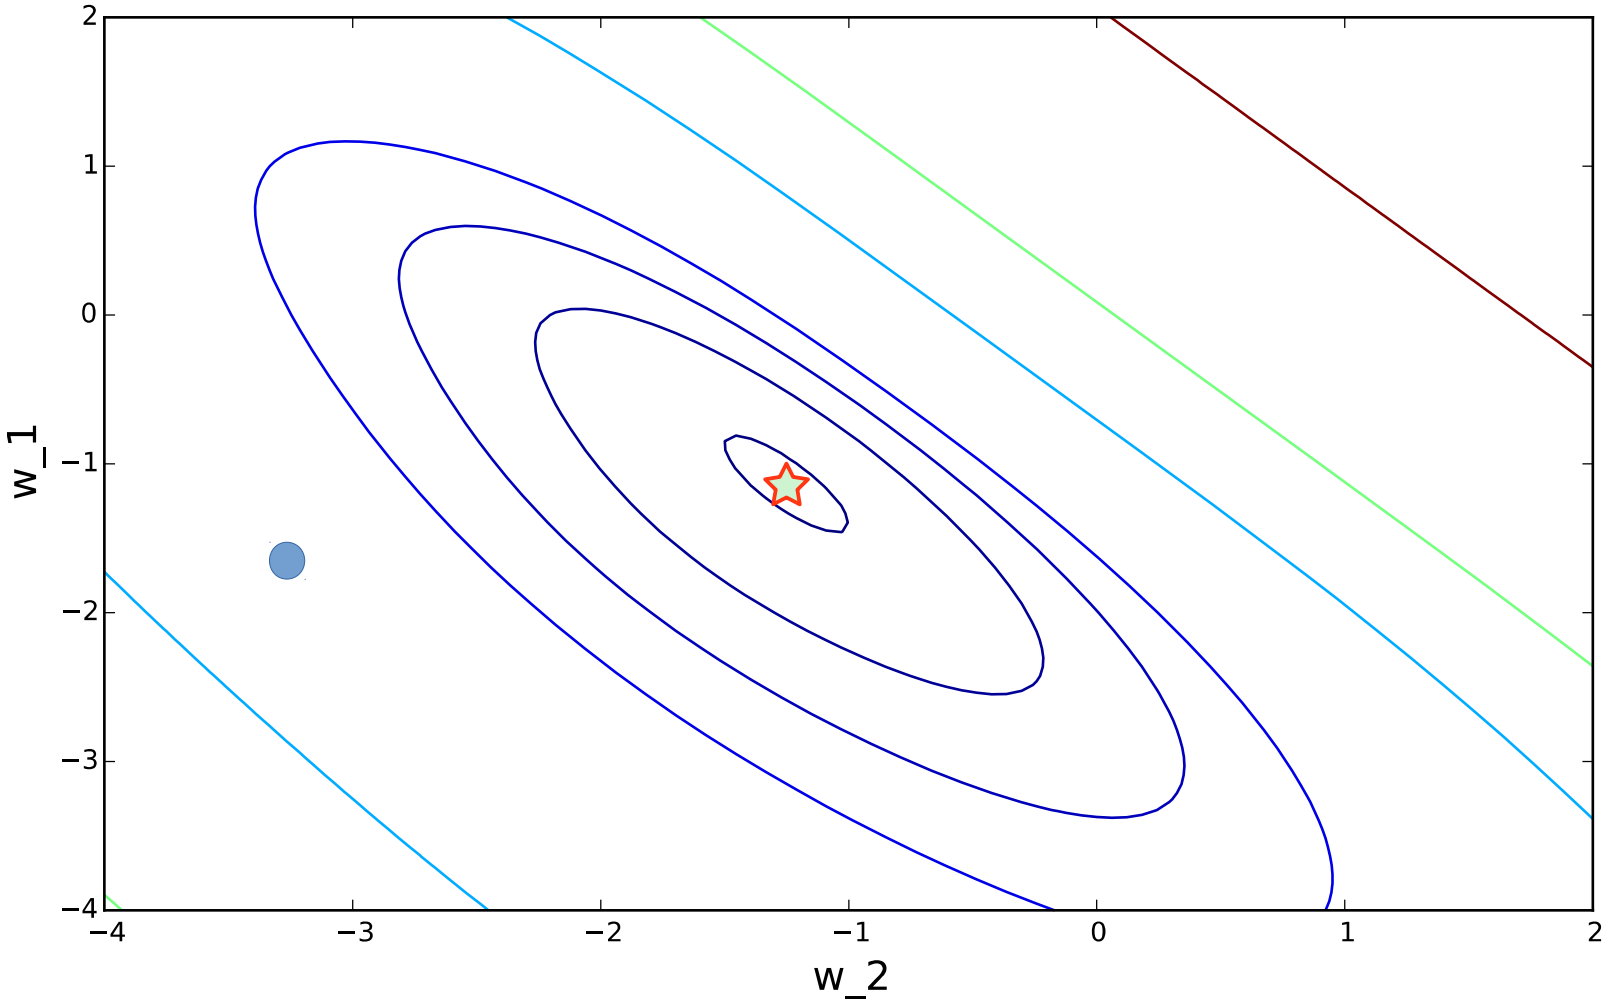

Descida de gradiente

$\mathbf{w}^{(0)}$

Gradiente
$-\nabla_{\mathbf{w}} L$

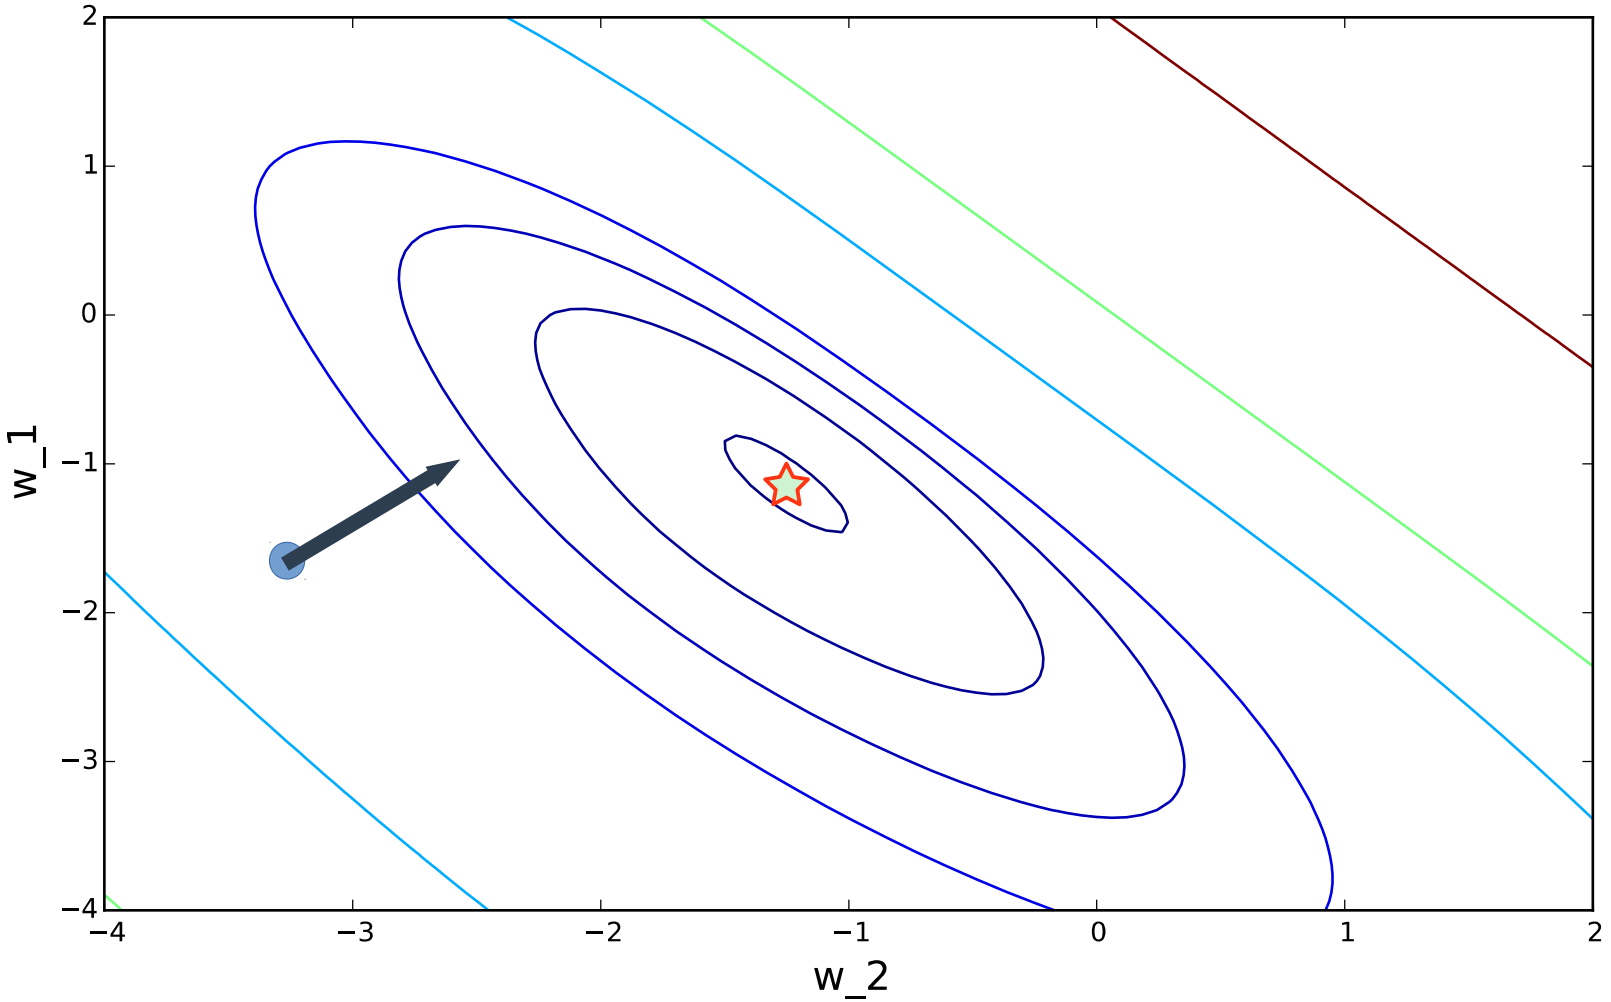

Descida de gradiente

$\mathbf{w}^{(0)}$

$\mathbf{w}^{(1)}$

Gradiente
$-\nabla_{\mathbf{w}} L$

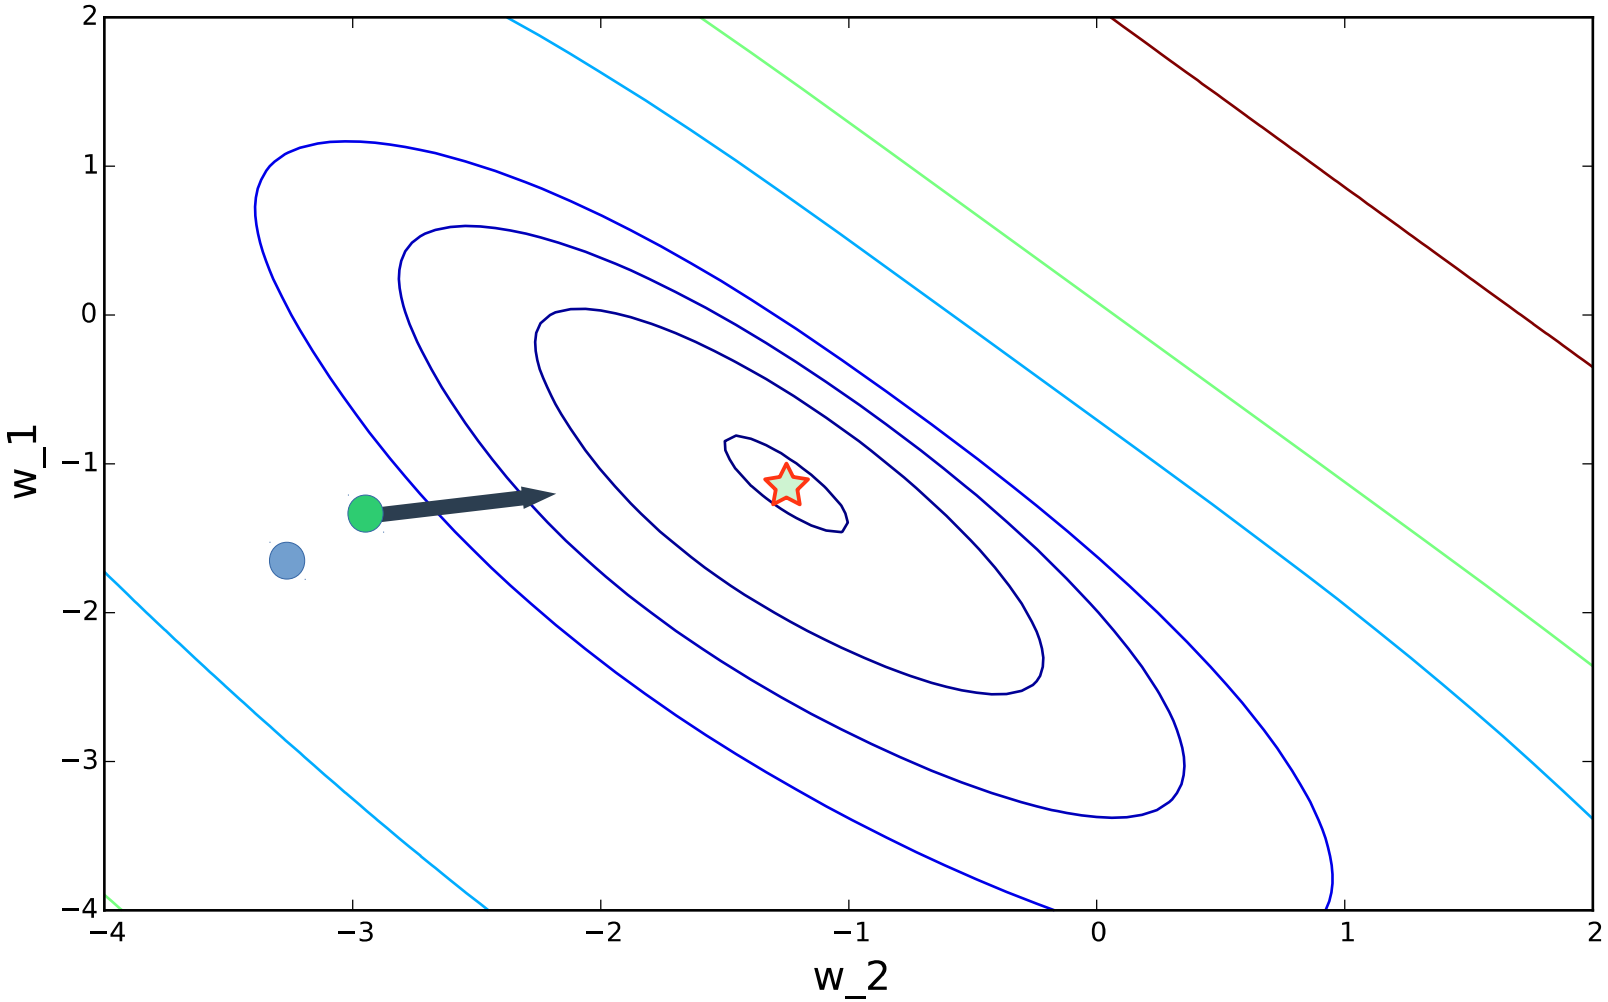

Descida de gradiente

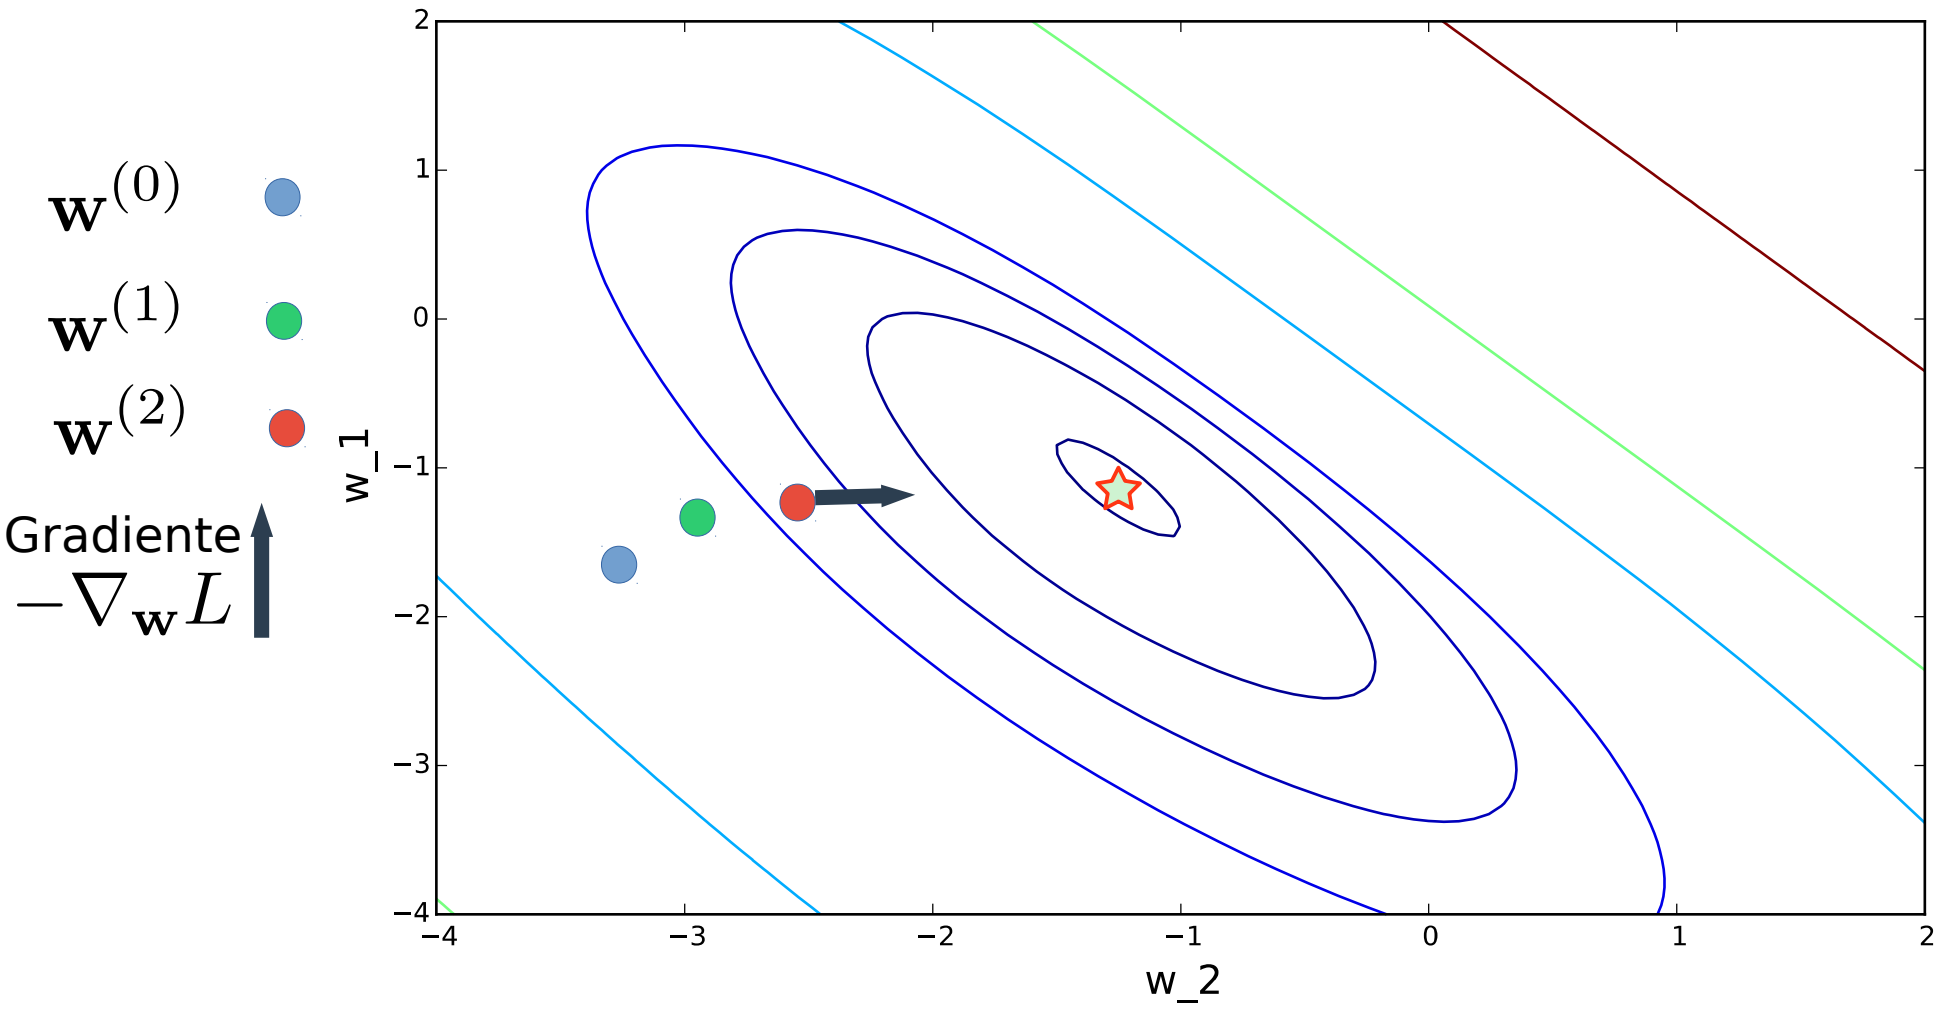

Overfitting

O importante é o <u>erro para novos exemplos</u> (generalização),

Mas durante o treinamento, minimizamos o erro na base de treinamento

Se os modelos forem multo complexos, podem entrar em "overfitting"

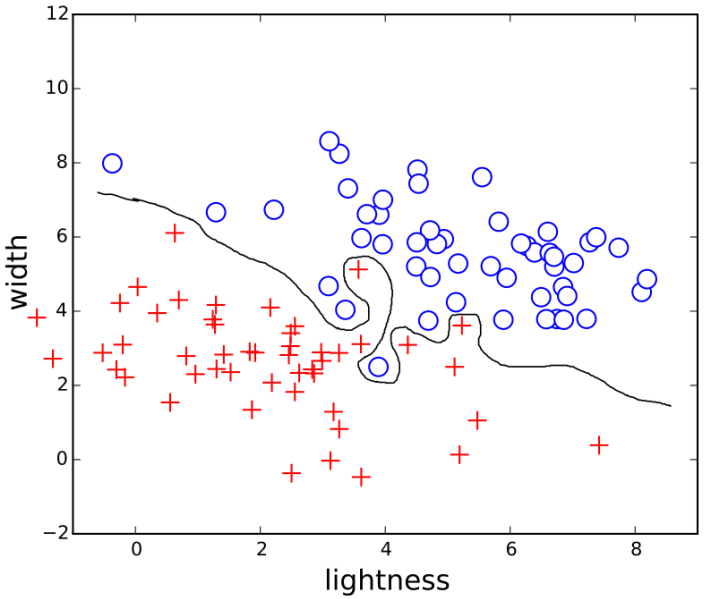

Overfitting

Overfitting

- **Estimar o erro em generalização:**
  - Manter uma base de teste separada (precisa conter exemplos diferentes, para evitar viés / bias)

Overfitting

- **Estimar o erro em generalização:**
  - Manter uma base de teste separada (precisa conter exemplos diferentes, para evitar viés / bias)
  - Para escolher hyper-parâmetros, (e.g. tipo de modelo, caractéristicas a serem usadas), usar uma outra base de dados:

Overfitting

- **Estimar o erro em generalização:**
  - Manter uma base de teste separada (precisa conter exemplos diferentes, para evitar viés / bias)
  - Para escolher hyper-parâmetros, (e.g. tipo de modelo, caractéristicas a serem usadas), usar uma outra base de dados:

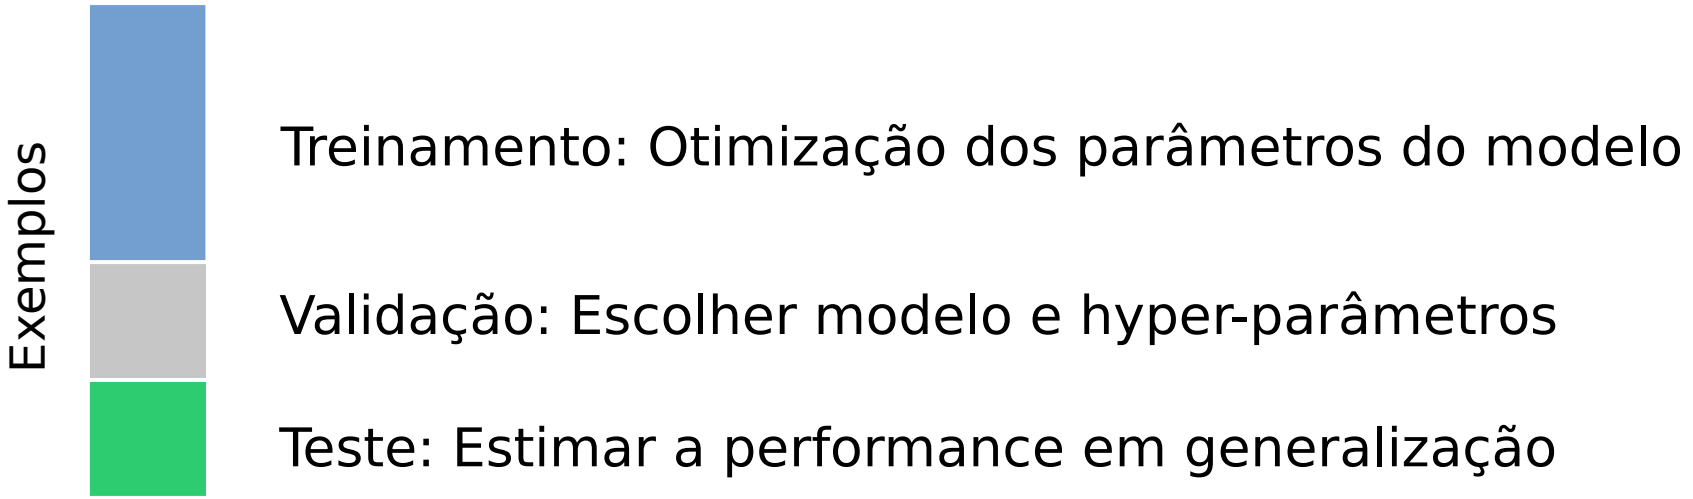

Exemplo: seleção de modelos

Treine diferentes modelos na base de treinamento

Avalie a performance em validação. Escolha o melhor modelo

Teste a performance do modelo na base de teste

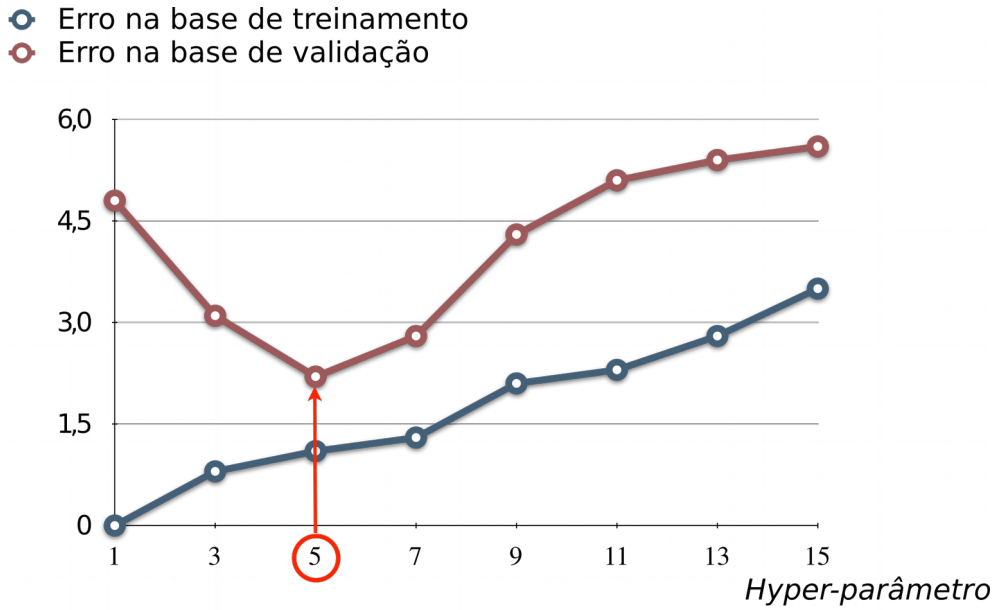

Melhor hyper-parâmetro segundo base de validação: **5**
(Segundo a base de treinamento: **1**)

Introdução ao Theano

Computação simbólica

Expressões são definidas em grafos. Exemplo: e = ab + c

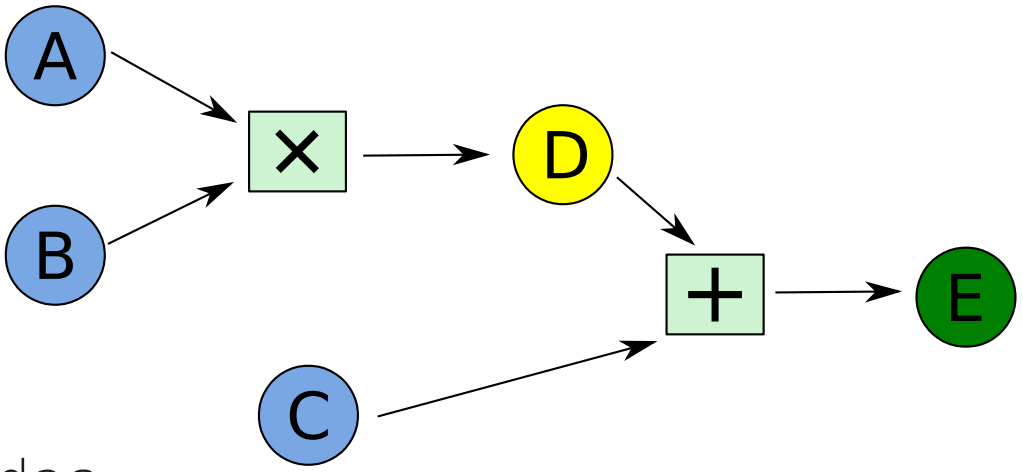

azul: entradas

amarelo: vértices intermediários

Verde: saídas

Introdução ao Theano

Expressões precisam ser compiladas

```
a = T.scalar()
b = T.scalar()
c = T.scalar()
e = a*b + c
f = theano.function([a,b,c],e)
f(2,4,10) #retorna 2*4+10 = 18
```

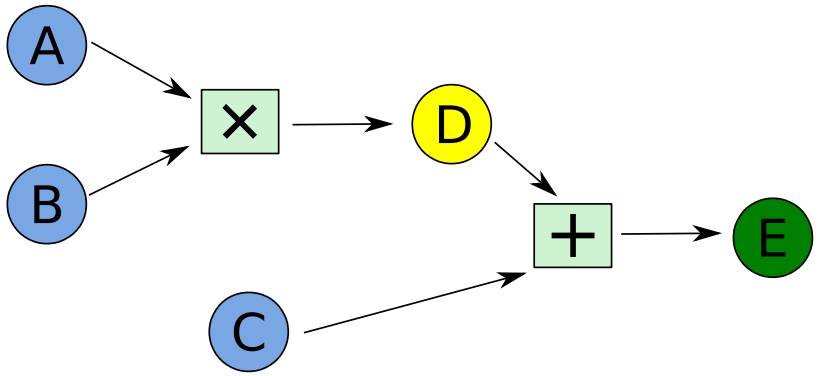

Permite derivação automática:

```
de_da = T.grad(e, a)
g = theano.function([a,b,c], de_da)
g(2,4,10) # retorna 4
```

Dois tipos de varíaveis

Variável simbólica

- Não possui estado.
- É informada na chamada de uma função, ou computada à partir de outras variáveis

- **Variável compartilhada**
  - Possui estado

Dois tipos de varíaveis

Variável simbólica

- Não possui estado.
- É informada na chamada de uma função, ou computada à partir de outras variáveis

- **Variável compartilhada**
  - Possui estado

```
a = T.scalar()          # Variável simbólica
```

Dois tipos de varíaveis

Variável simbólica

- Não possui estado.
- É informada na chamada de uma função, ou computada à partir de outras variáveis

- **Variável compartilhada**
  - Possui estado

```
a = T.scalar()             # Variável simbólica
b = theano.shared(2)  # Variável compartilhada, com valor 2
```

Dois tipos de varíaveis

Variável simbólica

- Não possui estado.
- É informada na chamada de uma função, ou computada à partir de outras variáveis

- **Variável compartilhada**
  - Possui estado

```
a = T.scalar()             # Variável simbólica
b = theano.shared(2)  # Variável compartilhada, com valor 2
c = theano.shared(1)  # Variável compartilhada, com valor 1
```

Dois tipos de varíaveis

Variável simbólica

- Não possui estado.
- É informada na chamada de uma função, ou computada à partir de outras variáveis

- **Variável compartilhada**
  - Possui estado

```
a = T.scalar()              # Variável simbólica
b = theano.shared(2)  # Variável compartilhada, com valor 2
c = theano.shared(1)  # Variável compartilhada, com valor 1
e = a*b + c
```

Dois tipos de varíaveis

Variável simbólica

- Não possui estado.
- É informada na chamada de uma função, ou computada à partir de outras variáveis

- **Variável compartilhada**
  - Possui estado

```
a = T.scalar()             # Variável simbólica
b = theano.shared(2)  # Variável compartilhada, com valor 2
c = theano.shared(1)  # Variável compartilhada, com valor 1
e = a*b + c

f = theano.function([a],e)
```

Dois tipos de varíaveis

Variável simbólica

- Não possui estado.
- É informada na chamada de uma função, ou computada à partir de outras variáveis

- **Variável compartilhada**
  - Possui estado

```
a = T.scalar()              # Variável simbólica
b = theano.shared(2)  # Variável compartilhada, com valor 2
c = theano.shared(1)  # Variável compartilhada, com valor 1
e = a*b + c

f = theano.function([a],e)
f(3)  # na chamada, informamos o valor de a.
```

Dois tipos de varíaveis

Variável simbólica

- Não possui estado.
- É informada na chamada de uma função, ou computada à partir de outras variáveis

- **Variável compartilhada**
  - Possui estado

```
a = T.scalar()              # Variável simbólica
b = theano.shared(2)  # Variável compartilhada, com valor 2
c = theano.shared(1)  # Variável compartilhada, com valor 1
e = a*b + c

f = theano.function([a],e)
f(3)  # na chamada, informamos o valor de a.
#retorna 3*2+1 = 7
```

Ipython Notebook

DEMO